# Détecteur d'arnaques vocales — Plan technique & équipe

Oct 10, 2026 · @Victor

## En bref

On construit un garde-fou qui écoute l'appel via Twilio, calcule un score de risque en direct à partir de quatre signaux, et protège la victime pendant l'appel : alerte chuchotée, mise en attente du scammeur, SMS au vrai proche.

- **Quatre signaux** : le contenu de l'appel (Claude sur Bedrock), des mots-clés pondérés, la voix synthétique (modèle de détection), la réputation du numéro (Twilio Lookup + contacts connus).
- **Principe** : le contenu et la vérification auprès du vrai contact portent la décision. La voix synthétique est un indice, jamais un verdict à elle seule.
- **Démo visée** : un coéquipier appelle « la grand-mère » avec une voix clonée. En cours d'appel, l'alerte se déclenche, le scammeur passe en attente et le vrai contact reçoit « C'est toi qui appelles ? ».

La durée du hackathon n'est pas fixée ici : le planning est en heures relatives (H0 = début du build), à recaler sur l'heure de rendu.

## Stack technique

Tout tient dans un backend Python unique (FastAPI) ; Twilio porte l'appel, AWS porte la transcription et l'analyse. Les contraintes ci-dessous viennent de la documentation, la colonne de droite dit qui s'en occupe.

| Brique | Choix | Contrainte vérifiée / à tester | Qui |
|---|---|---|---|
| Appels | Twilio Programmable Voice, numéro US | Compte d'essai : appels seulement vers et depuis des numéros vérifiés, un seul numéro Twilio, appels limités au pays d'inscription. Un numéro français exige un *regulatory bundle* (pièce d'identité + adresse en France) : prendre un numéro US. Si possible, créditer le compte (~20 $) pour lever ces limites. | Dev 1 |

| Brique | Choix | Contrainte vérifiée / à tester | Qui |
|---|---|---|---|
| Capture audio | `<Start><Stream track="both_tracks">` puis `<Dial><Conference>` | Stream unidirectionnel, compatible avec la conférence. Audio µ-law 8 kHz en base64 ; les pistes *inbound* / *outbound* séparent appelant et victime, donc on sait qui parle. | Dev 1 |
| Serveur | Python FastAPI + WebSocket, exposé en `wss://` via ngrok | Python 3.14 : le module `audioop` n'existe plus depuis 3.13. Installer `audioop-lts` ou décoder le µ-law avec numpy. | Dev 1 |
| Transcription | Amazon Transcribe streaming (SDK `amazon-transcribe`), `fr-FR`, PCM 8000 Hz | Français supporté en streaming, 8 kHz accepté. À tester à H0 : le rôle workshop autorise-t-il `transcribe:StartStreamTranscription` ? | Dev 1 |
| Analyse du contenu | Claude Sonnet 4.5 sur Bedrock (`us-west-2`), sortie JSON | Appel déjà validé. Latence à mesurer : appeler Claude sur chaque segment final, avec une fenêtre glissante du transcript. | Dev 2 |
| Mots-clés | Regex Python, liste FR + EN pondérée | Réagit instantanément, sert de filet si Claude est lent. | Biz 1 (liste), Dev 2 (code) |
| Voix synthétique | Modèle wav2vec2 de Hugging Face (`transformers` + `torch`, CPU) | Les modèles publiés attendent du 16 kHz propre : suréchantillonner 8 → 16 kHz, fenêtres de 4 s, et tester sur de l'audio passé par le téléphone. Plusieurs fiches de modèles reconnaissent | Dev 2 |

| Brique | Choix | Contrainte vérifiée / à tester | Qui |
|---|---|---|---|
| | | une mauvaise généralisation. | |
| Réputation | Twilio Lookup v2 `line_type_intelligence` + fichier de contacts | Renvoie mobile, fixe, *fixed VoIP*, *nonFixedVoip*… Service payant à la requête. | Dev 2 |
| Actions | API REST Twilio Participants (`hold`, `hold_url`, `announce_url`) + SMS | Le *whisper* / *coach* exige l'Agent Conference activée dans la console (sinon erreur 16000) : tenter d'abord l'annonce par participant. | Dev 1 |
| Dashboard | Page HTML/JS servie par FastAPI, flux d'événements en WebSocket | Plus simple et plus fluide que Streamlit pour du temps réel. | Biz 1 + Dev 2 |
| Voix clonée (démo) | Outil de clonage vocal, voix d'un coéquipier consentant | Garder des enregistrements en secours si le réseau lâche. | Biz 1 |

**Contrat commun, à figer à H0.** Chaque brique émet et consomme ce format d'événement ; chacun peut avancer avec de faux événements avant que le reste marche.

```
{"call_id": "CA123", "t": 12.4, "type": "transcript | keyword | llm | voice | reputation | score | action",
 "speaker": "caller | victim", "data": {"text": "…", "risk": 0.82, "reasons": ["urgence", "paiement inhabituel"]}}
```

## Scoring

Le score va de 0 à 100 : somme pondérée des quatre signaux, plus trois règles coupe-circuit pour qu'un signal très fort ne soit pas dilué par la moyenne. Les poids sont un point de départ, à calibrer sur les scénarios de test de Biz 1.

| Signal | Ce qu'il mesure | Poids proposé |
|---|---|---|
| Claude (contenu) | Le scénario d'arnaque : urgence, secret, paiement inhabituel, | 45 |

| Signal | Ce qu'il mesure | Poids proposé |
|---|---|---|
| | fausse autorité, identité revendiquée | |
| Mots-clés | Termes à risque pondérés (« carte bancaire », « urgence », « virement », « ne dis rien ») | 20 |
| Voix synthétique | Probabilité « fake » du modèle, lissée sur plusieurs fenêtres | 20 |
| Réputation | Ligne VoIP, numéro absent des contacts, numéro différent de celui de la personne revendiquée | 15 |

**Seuils** : moins de 40, rien ; 40 à 64, vigilance ; 65 à 84, alerte ; 85 et plus, intervention (détail dans la section suivante).

**Règles coupe-circuit**

1. Demande de paiement inhabituel (cartes cadeaux, crypto, coursier, virement urgent) **et** identité revendiquée qui ne correspond pas au numéro : score porté à 85 minimum.
2. Risque Claude ≥ 0,9 : score porté à 65 minimum, quels que soient les autres signaux.
3. La voix synthétique seule ne fait jamais dépasser 64 : elle peut aggraver, pas déclencher une intervention. Cela limite les faux positifs.

**Sortie attendue de Claude** (JSON imposé dans le prompt) : `risk` entre 0 et 1, `tactics` (liste), `claimed_identity` (« Lucas, petit-fils » ou null), `explanation` en une phrase, réutilisée telle quelle dans l'alerte et le dashboard.

## Alertes pendant l'appel

La victime a le téléphone à l'oreille : on lui parle dans l'appel, pas par email. Comme l'appel passe par une conférence Twilio, le backend peut agir sur chaque participant séparément.

1. **Vigilance (40 à 64)** : rien d'audible. Le dashboard passe à l'orange et un proche de confiance reçoit une notification.
2. **Alerte (65 à 84)** : annonce à la victime seule, via `announce_url` sur son participant (TwiML `<Say language="fr-FR">`) : « Attention, cet appel présente des signes d'arnaque. Ne donnez aucune information bancaire. » En parallèle, SMS au vrai contact : « Est-ce toi qui appelles en ce moment ? »
3. **Intervention (85 et plus)** : le scammeur passe en attente (`hold=true`, musique), puis annonce à la victime : « Nous avons mis l'appel en pause et prévenu Lucas. » L'appel peut reprendre si la victime le souhaite.

**Pas de raccrochage automatique.** Un faux positif sur un vrai appel d'urgence serait grave ; la mise en attente protège autant et laisse la décision à la victime.

**À tester en premier (H0 à H1)** : que l'annonce n'est entendue que par la victime. Sinon, plan B : coach via Agent Conference, ou mise en attente du scammeur avant chaque annonce.

## Rôles

Les deux devs portent le pipeline temps réel ; les deux profils business portent tout ce que le jury voit, et codent sur les parties à faible risque (dashboard, mots-clés, scénarios). Noms à attribuer.

| Rôle | Responsabilités | Premier livrable |
|---|---|---|
| **Dev 1 — Téléphonie & temps réel** | Compte et numéro Twilio, TwiML (stream + conférence), serveur WebSocket + ngrok, décodage μ-law, Transcribe streaming, actions Twilio (annonce, attente, SMS) | Un appel réel produit un transcript live dans la console |
| **Dev 2 — Intelligence & score** | Prompt Claude + sortie JSON, moteur de mots-clés, modèle de voix synthétique, Lookup + contacts, moteur de score, envoi des événements au dashboard | Le score réagit à un transcript texte, sans téléphone |
| **Biz 1 — Produit & démo** | 3 scénarios d'arnaque + 2 appels légitimes (tests de faux positifs), liste de mots-clés FR, voix clonée (avec consentement), dashboard HTML avec Dev 2, script de démo minuté | Les 5 scénarios écrits et enregistrés |
| **Biz 2 — Pitch & business** | Problème et chiffres sourcés, persona, modèle économique (opérateurs, banques, assureurs, offre famille), RGPD et consentement à l'enregistrement, deck, répétitions, réponses aux questions du jury, vidéo de secours de la démo | Plan du deck et message clé en une phrase |

**Règle d'équipe** : le format d'événement (section Stack) est figé à H0. Dev 2 et Biz 1 travaillent sur des faux événements tant que la téléphonie n'est pas prête.

## Risques et plan B

Le plus gros risque est la téléphonie, d'où les tests à H0 ; tout le reste a une solution de repli.

| Risque | Plan B |
|---|---|
| Le compte Twilio d'essai bloque des appels (numéro non vérifié, autre pays) | Vérifier à l'avance tous les téléphones de la démo, ou créditer le compte |
| Le réseau du lieu bloque Bedrock ou Twilio (déjà vu avec Bedrock) | Hotspot téléphone dédié à la démo + vidéo enregistrée |
| L'annonce est entendue aussi par le scammeur | Coach via Agent Conference, ou mise en attente du scammeur avant l'annonce |
| Latence trop forte (Transcribe + Claude) | Les mots-clés déclenchent seuls la vigilance ; Claude toutes les N secondes |
| Modèle de voix peu fiable sur audio téléphonique | Poids réduit, présenté comme un indice ; il ne déclenche jamais seul |
| Le rôle workshop n'autorise pas Transcribe | Tester à H0 ; sinon transcription locale (Whisper) par morceaux |
| Identifiants AWS expirés pendant la démo | Les rafraîchir juste avant de passer, dans `~/.aws/credentials` |
| Question du jury sur la vie privée | Biz 2 prépare la réponse : consentement, pas de stockage de l'audio, transcript effacé après l'appel |

## Sources


- Twilio — Media Streams, messages WebSocket
- Twilio — TwiML `<Stream>`
- Twilio — Voice Conference (coaching / whisper)
- Twilio — erreur 16000 : whisper indisponible hors Agent Conference
- Twilio — Lookup v2, Line Type Intelligence
- Twilio — limites du compte d'essai
- Twilio — exigences réglementaires France
- AWS — StartStreamTranscription
- AWS — langues supportées par Transcribe
- Hugging Face — exemple de détecteur et ses limites de généralisation